

Федеральное государственное образовательное
учреждение
высшего образования
«Московский государственный технический университет имени
Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

Факультет ИУ - «Информатика и управление»

Кафедра ИУ5 - «Системы обработки информации и управления»

Лабораторная работа №1 по курсу «Технологии машинного
обучения»
на тему «Разведочный анализ данных. Исследование и
визуализация данных.»

Студент: Серенков Иван Дмитриевич

Преподаватель кафедры ИУ5: Ованнес Гагикович Саргсян

1. Цель работы

Провести разведочный анализ табличного набора данных о странах мира: изучить размер и структуру датасета, определить типы признаков и наличие пропущенных значений, рассчитать основные статистические характеристики, а также выполнить визуальный анализ распределений и взаимосвязей между признаками.

2. Используемые средства

В работе используется Python 3 в среде Jupyter Notebook. Для загрузки и обработки данных применяются библиотеки NumPy и Pandas, для визуализации - Seaborn и Matplotlib. Графики выводятся непосредственно в notebook.

```
import numpy as np
import pandas as pd
import seaborn as sns
import matplotlib.pyplot as plt
%matplotlib inline
sns.set(style="ticks")
```

3. Исходные данные

Исходный набор данных загружается из файла country_stats.csv с помощью функции pandas.read_csv. Фактический результат data.shape показывает 195 строк и 13 столбцов.

```
data = pd.read_csv('country_stats.csv', sep=',')
data.shape # (195, 13)
```

Набор описывает географические, демографические и социально-экономические характеристики стран. В данных присутствуют 11 числовых признаков и 2 признака типа object. Поле External debt (billions) загружено как object, поэтому оно не участвует в стандартной числовой статистике и корреляционном анализе без дополнительного преобразования.

Таблица 1 - Структура набора данных

Признак	Тип	Содержание
Country name	object	Название страны
Total in km2	float64	Общая площадь, км²
Land in km2	float64	Площадь суши, км²
Inland water in km2	float64	Площадь внутренних вод, км²
% water	float64	Доля водной поверхности, %
Population	float64	Численность населения
% of world population	float64	Доля мирового населения, %

Признак	Тип	Содержание
Population density	float64	Плотность населения
HDI	float64	Индекс человеческого развития
Fertility rate	float64	Коэффициент рождаемости
Mortality rate	float64	Коэффициент смертности
% of internet users in population	float64	Доля интернет-пользователей, %
External debt (billions)	object	Внешний долг, млрд

4. Первичный анализ данных

4.1. Проверка пропущенных значений

Для каждого столбца подсчитано число пустых значений. Полностью заполнены Country name и Total in km2. В остальных признаках количество пропусков невелико: от 1 до 8 значений. Наибольшее число пропусков обнаружено в Mortality rate.

```
for col in data.columns:
    temp_null_count = data[data[col].isnull()].shape[0]
    print('{} - {}'.format(col, temp_null_count))
```

Таблица 2 - Количество пропущенных значений

Признак	Пропуски
Land in km2	1
Inland water in km2	1
% water	1
Population	1
% of world population	1
Population density	1
HDI	5
Fertility rate	4
Mortality rate	8
% of internet users in population	6
External debt (billions)	5

Ключевое наблюдение. Пропуски распределены по нескольким признакам и не образуют крупного

систематического блока. Для дальнейшего машинного обучения потребуется выбрать стратегию их обработки.

4.2. Описательная статистика

Команда `data.describe()` показывает основные статистические характеристики числовых признаков. Значительные различия между средними и медианами для площади, населения и плотности населения указывают на сильную асимметрию распределений и наличие стран с экстремально большими значениями.

Таблица 3 - Основные статистические характеристики

Признак	count	mean	median	min	max
Total in km2	195	685 093,6	118 484	0,44	17 098 250
Population	194	41 395 280	9 244 136	882	1 429 404 000
Population density	194	317,36	86,57	2,30	19 428,50
HDI	190	0,740	0,762	0,388	0,972
Fertility rate	191	2,35	1,93	0,76	5,84
Mortality rate	187	7,56	6,99	1,42	21,70
Internet users, %	189	70,70	82,00	0,00	100,00

5. Визуальный анализ

5.1. Связь численности населения и площади страны

Диаграмма рассеяния построена для признаков Population и Total in km2. Основная масса стран сосредоточена в области относительно небольших значений обоих признаков. Одновременно присутствуют выраженные выбросы: отдельные страны имеют очень большую площадь или население. Строгой линейной зависимости между площадью и численностью населения не наблюдается.

```
fig, ax = plt.subplots(figsize=(10,10))
sns.scatterplot(ax=ax, x='Population', y='Total in km2', data=data)
```




Рисунок 1 - Диаграмма рассеяния Population и Total in km2

График показывает, что большая площадь страны сама по себе не означает пропорционально большую численность населения. Для этих признаков заметна концентрация большинства наблюдений около начала координат и несколько стран-гигантов, существенно удаленных от основной группы.

5.2. Boxplot числовых признаков

Для всех числовых признаков построены диаграммы размаха. Наиболее заметные выбросы наблюдаются у общей площади, численности населения и плотности населения. Это ожидаемо для межстрановых данных: небольшое число государств сильно отличается от большинства по масштабу.




Рисунок 2 - Примеры boxplot для площади, населения, плотности населения и HDI

5.3. Анализ категориальных признаков

По признакам типа object построены диаграммы десяти наиболее частых значений. Для Country name каждое название страны является отдельной категорией, поэтому частоты в основном равны единице и такая диаграмма имеет ограниченную аналитическую ценность. Признак External debt (billions) также содержит большое число различных строковых значений; перед моделированием его целесообразно преобразовать в числовой формат.




Рисунок 3 - Топ-10 значений категориального признака Country name

5.4. Парные зависимости числовых признаков

Для первых четырех числовых признаков построена матрица попарных диаграмм. Наиболее выраженная связь наблюдается между Total in km2 и Land in km2: увеличение общей площади почти полностью сопровождается увеличением площади суши. Связи с площадью внутренних вод и долей воды имеют больший разброс.




Рисунок 4 - Матрица парных диаграмм первых четырех числовых признаков

5.5. Корреляционная матрица

Для всех числовых признаков рассчитана корреляционная матрица и построена тепловая карта. Наиболее сильные положительные связи, выведенные в notebook, наблюдаются между Population и % of world population (0,9999), а также между Land in km2 и Total in km2 (0,9996). Сильная связь также выявлена между HDI и долей интернет-пользователей (0,8644).

```
corr = data[num_cols].corr()
sns.heatmap(corr, annot=True, fmt=".2f", cmap="coolwarm",
            square=True, linewidths=0.5)
```




Рисунок 5 - Тепловая карта корреляций числовых признаков

Таблица 4 - Наиболее коррелирующие пары признаков

Пара признаков	Коэффициент корреляции
Population - % of world population	0,999927
Land in km2 - Total in km2	0,999614
HDI - % of internet users in population	0,864437
Total in km2 - Inland water in km2	0,828604
Land in km2 - Inland water in km2	0,812726

5.6. Карта пропущенных значений

Тепловая карта `data.isnull()` позволяет увидеть расположение пропусков по строкам и признакам. На графике преобладает заполненная область; пропуски встречаются точечно и сосредоточены только в части столбцов. Это согласуется с количественным подсчетом из раздела 4.1.




Рисунок 6 - Карта пропущенных значений

6. Основные результаты

- Размер исходного набора данных - 195 объектов и 13 признаков.
- Определено 11 числовых признаков и 2 признака типа object.
- Полностью заполнены Country name и Total in km2; в остальных столбцах присутствует от 1 до 8 пропусков.
- Распределения площади, населения и плотности населения имеют выраженную асимметрию и содержат выбросы.
- Диаграмма Population - Total in km2 не показывает строгой линейной зависимости.
- Наиболее сильная корреляция наблюдается между Population и % of world population (0,999927), а также между Land in km2 и Total in km2 (0,999614).
- HDI положительно связан с долей интернет-пользователей (корреляция 0,864437).
- External debt (billions) хранится как object и требует преобразования в числовой формат перед использованием в моделях.

7. Вывод

В ходе лабораторной работы выполнен базовый цикл разведочного анализа данных: загрузка набора, просмотр первых строк, определение размера и типов признаков, проверка пропусков, расчет описательной статистики и построение нескольких видов визуализаций. Анализ показал, что межстрановые показатели имеют существенно различающиеся масштабы и часто содержат выраженные выбросы. Особенно сильные линейные связи наблюдаются между численностью населения и долей мирового населения, а также между общей площадью и площадью суши. Дополнительно выявлена заметная связь HDI с распространенностью интернета. Перед дальнейшим машинным обучением необходимо обработать пропущенные значения и привести External debt (billions) к числовому типу. В целом набор данных подходит для последующего анализа и построения моделей после выполнения этих этапов предобработки.